

Tecnicatura Superior Ciencia de Datos e Inteligencia Artificial

Pronuncia: Evaluación automática de pronunciación en japonés

Proyecto ABP

Materia: Técnicas de Procesamiento del Habla

Integrantes:

- Emilce Robles
- Marini Ian

Docente:

- Rubén Emmanuel GIUDICE BOJANICH

Estructura para el diseño de Proyectos ABP

1. **NOMBRE DEL PROYECTO: PronunciaIA:** Evaluación automática de pronunciación en japonés mediante Procesamiento del Habla e IA
2. **TIPO DE PROYECTO:** Proyecto tecnológico orientado al desarrollo de una solución basada en técnicas de Procesamiento del Habla e Inteligencia Artificial para la evaluación automática de pronunciación en un idioma extranjero.
3. **ESPACIO CURRICULAR O ESPACIOS PARTICIPANTES EN EL MÓDULO:** Técnicas de Procesamiento del Habla
4. **EJES TEMÁTICOS/RED DE CONCEPTOS:**

Los ejes temáticos abordados en el proyecto son:

- Procesamiento Digital de Señales.
- Adquisición y tratamiento de audio.
- Extracción de características acústicas.
- Ingeniería de características (Features).
- Aprendizaje Automático aplicado al habla.
- Síntesis de voz (Text-to-Speech).
- Comparación y evaluación de señales de audio.
- Inteligencia Artificial aplicada al lenguaje.

Competencias y habilidades fortalecidas:

- a. Análisis de señales de audio.
- b. Manipulación y preparación de datasets.
- c. Desarrollo de soluciones basadas en IA.
- d. Aplicación práctica de herramientas de procesamiento del habla.
- e. Resolución de problemas mediante programación en Python.
- f. Documentación técnica y comunicación de resultados.

5. PROBLEMÁTICAS/NECESIDADES: El aprendizaje de idiomas suele requerir retroalimentación constante sobre la pronunciación. Sin embargo, muchas personas no tienen acceso permanente a docentes o hablantes nativos que puedan corregir errores fonéticos.

Esta situación genera dificultades para identificar si una palabra o frase está siendo pronunciada correctamente, especialmente en idiomas que presentan sonidos diferentes al español, como el japonés.

Ante esta necesidad surge la posibilidad de desarrollar una herramienta capaz de analizar grabaciones de voz y compararlas con pronunciaciones de referencia, brindando una evaluación objetiva basada en características acústicas.

6. FUNDAMENTACIÓN: Se eligió esta problemática debido a que combina de manera práctica los contenidos estudiados durante la materia Técnicas de Procesamiento del Habla con una aplicación real relacionada con el aprendizaje de idiomas.

El proyecto posee potencial educativo porque permite demostrar cómo las técnicas de procesamiento de audio pueden utilizarse para asistir procesos de aprendizaje, incorporando conceptos de inteligencia artificial, análisis de señales y extracción de características acústicas.

Desde la perspectiva profesional, el desarrollo permite aplicar conocimientos vinculados al tratamiento de datos de audio, preparación de datasets, análisis de características y construcción de sistemas inteligentes.

A nivel social, este tipo de herramientas puede contribuir al aprendizaje autónomo de idiomas, facilitando el acceso a mecanismos de práctica y retroalimentación para estudiantes que no disponen de acompañamiento permanente de docentes especializados.

7. VISIÓN DEL PROYECTO: Desarrollar una solución educativa basada en Procesamiento del Habla e Inteligencia Artificial que permita evaluar automáticamente la pronunciación de palabras y frases en japonés, promoviendo el aprendizaje autónomo mediante el análisis de grabaciones de voz y su comparación con modelos de referencia.

DISEÑO DE LOS OBJETIVOS

- **Objetivo general:** Desarrollar un sistema de evaluación automática de pronunciación que permita comparar grabaciones realizadas por usuarios con audios de referencia en idioma japonés mediante técnicas de procesamiento del habla e inteligencia artificial.
- **Objetivos específicos:**
 - Generar un conjunto de audios de referencia utilizando síntesis de voz.
 - Construir un dataset de pronunciaciones realizadas por usuarios.
 - Aplicar técnicas de preprocesamiento y normalización de audio.
 - Extraer características acústicas relevantes de las señales de voz.
 - Comparar pronunciaciones mediante métricas de similitud.
 - Analizar los resultados obtenidos y determinar el grado de correspondencia entre la pronunciación del usuario y la referencia.
- **Metas:** Desarrollar un prototipo funcional capaz de evaluar la pronunciación de palabras y frases en japonés mediante el análisis de grabaciones de voz, generando resultados comparativos que permitan identificar el nivel de similitud respecto a una pronunciación de referencia durante el período de desarrollo del proyecto.

8. SELECCIÓN DE ACCIONES

OBJETIVO ESPECÍFICO	ACCIONES
Generar audios de referencia	Seleccionar vocabulario, generar audios mediante Text-to-Speech y almacenarlos para comparación.
Construir dataset de usuario	Realizar grabaciones de pronunciación y organizar los archivos de audio.
Aplicar preprocesamiento	Normalizar señales y unificar formatos de audio.
Extraer características	Calcular MFCC, energía RMS, Spectral Centroid y Zero Crossing Rate.
Comparar pronunciaciones	Aplicar métricas de similitud entre audios de referencia y audios del usuario.
Analizar resultados	Interpretar resultados y evaluar el desempeño del sistema.

9. CRONOGRAMA:

CRONOGRAMA	MES O SEMANA 1	MES O SEMANA 2	MES O SEMANA 3	MES O SEMANA 4
Investigación y definición del problema	X			
Selección de vocabulario	X			
Generación de audios de referencia	X	X		
Grabación de audios de usuario		X		
Generación de audios sintéticos		X		
Extracción de características			X	

Comparación y evaluación			X	X
Documentación y presentación				X

10. PRODUCTO FINAL:

El producto final desarrollado consiste en **PronunciaIA**, un sistema de evaluación automática de pronunciación en idioma japonés que integra técnicas de Procesamiento del Habla, análisis digital de señales e Inteligencia Artificial para comparar pronunciaciones realizadas por el usuario con audios de referencia generados automáticamente.

La solución fue implementada utilizando Python y Jupyter Notebook como entorno principal de desarrollo, apoyándose en bibliotecas especializadas como Librosa, SoundFile y Pydub para el procesamiento de audio; NumPy y Pandas para el tratamiento y análisis de datos; Matplotlib para la visualización de resultados; y SciPy para el cálculo de métricas de similitud. Asimismo, se utilizó Google Text-to-Speech (gTTS) para la generación automática de audios de referencia, mientras que Git y GitHub permitieron gestionar el control de versiones y la documentación del proyecto durante todo su ciclo de desarrollo. **Link al repositorio:** <https://github.com/emilce-robles/ISPC-Procesamiento-del-Habla-PronunciaIA>

La finalidad principal del sistema es ofrecer una herramienta de apoyo al aprendizaje de idiomas, permitiendo analizar grabaciones de voz y obtener una aproximación objetiva sobre el nivel de similitud acústica respecto de una pronunciación de referencia. En este caso, el idioma seleccionado fue el japonés, debido a que

presenta sonidos, ritmos y estructuras fonéticas diferentes al español, lo que representa un desafío interesante para el análisis de pronunciación.

Para el desarrollo de PronunciA se trabajó en un único notebook, donde se integraron todas las etapas del proceso: definición del vocabulario, generación de audios de referencia, carga de grabaciones del usuario, visualización de señales, extracción de características acústicas, generación de audios sintéticos, comparación de pronunciaciones y análisis de resultados.

En primer lugar, se construyó un vocabulario base compuesto por quince elementos en japonés. Este vocabulario fue organizado en tres grupos: palabras simples, expresiones cotidianas y frases cortas.

	id	texto_japones
0	neko	ねこ
1	raamen	ラーメン
2	sushi	すし
3	mizu	みず
4	densha	でんしゃ
5	arigatou	ありがとう
6	konnichiwa	こんにちは
7	ohayou	おはよう
8	sayounara	さようなら
9	sumimasen	すみません
10	ohayou_gozaimasu	おはようございます
11	arigatou_gozaimasu	ありがとうございます
12	sumimasen_eki_wa_doko_desu_ka	すみません 駅はどこですか
13	watashi_wa_emi_desu	わたしはエミです
14	raamen_ga_suki_desu	ラーメンが好きです

Figura 1. Dataset de vocabulario japonés utilizado en PronunciA.

Luego, se generaron los audios de referencia utilizando la librería **Google Text-to-Speech (gTTS)** configurada en idioma japonés. Estos audios funcionan como pronunciaciones modelo y fueron almacenados en la carpeta `audios/referencia/`. El notebook verifica si los archivos ya existen y, en caso

contrario, los crea automáticamente. Esta decisión permite que el proyecto sea reproducible, ya que cualquier persona que ejecute el notebook puede reconstruir los audios de referencia sin necesidad de obtenerlos manualmente desde una fuente externa.

```
audios/referencia\neko_ref.mp3
audios/referencia\raamen_ref.mp3
audios/referencia\sushi_ref.mp3
audios/referencia\mizu_ref.mp3
audios/referencia\densha_ref.mp3
audios/referencia\arigatou_ref.mp3
audios/referencia\konnichiwa_ref.mp3
audios/referencia\ohayou_ref.mp3
audios/referencia\sayounara_ref.mp3
audios/referencia\sumimasen_ref.mp3
audios/referencia\ohayou_gozaimasu_ref.mp3
audios/referencia\arigatou_gozaimasu_ref.mp3
audios/referencia\sumimasen_eki_wa_doko_desu_ka_ref.mp3
audios/referencia\watashi_wa_emi_desu_ref.mp3
audios/referencia\raamen_ga_suki_desu_ref.mp3
```

Figura 2. Generación automática de audios de referencia mediante gTTS.

Posteriormente, se incorporaron las grabaciones del usuario, ubicadas en la carpeta `audios/usuario/`. Cada archivo representa un intento de pronunciación correspondiente a una palabra, expresión o frase del vocabulario seleccionado. En la ejecución presentada, el sistema detectó 42 audios de usuario, grabados en formato `.mp4`. Para poder procesarlos correctamente, se adaptó la función de carga de audio a fin de convertir los archivos de audio a un formato compatible con Librosa cuando fuera necesario. Esta etapa fue importante porque permitió trabajar con grabaciones reales provenientes de un dispositivo cotidiano, acercando el proyecto a un escenario de uso práctico.

```
Cantidad de audios de usuario encontrados: 42  
  
['arigatou_01.mp4',  
 'arigatou_02.mp4',  
 'arigatou_03.mp4',  
 'arigatou_gozaimasu_01.mp4',  
 'arigatou_gozaimasu_02.mp4',  
 'arigatou_gozaimasu_03.mp4',  
 'densha_01.mp4',  
 'densha_02.mp4',  
 'densha_03.mp4',  
 'konnichiwa_01.mp4']
```

Figura 3. Detección y carga de grabaciones realizadas por el usuario.

Una vez cargados los audios, se realizó una primera etapa de visualización de señales. Para ello, se seleccionó el audio de referencia `neko_ref.mp3`, correspondiente a la palabra *neko*. El sistema cargó la señal con una frecuencia de muestreo uniforme de 16000 Hz y calculó una duración aproximada de 0,84 segundos. A partir de esta señal se generó una visualización de la forma de onda, donde se puede observar la variación de amplitud a lo largo del tiempo. En el gráfico se identifican claramente los segmentos sonoros de la palabra, separados por pequeños espacios de menor energía. Esta representación permite analizar la estructura temporal de la pronunciación.




Figura 4. Reproducción y carga del audio de referencia "neko".




Figura 5. Forma de onda correspondiente al audio de referencia "neko".

También se generó el espectrograma del mismo audio de referencia. Esta representación permite observar cómo se distribuye la energía de la señal en distintas frecuencias a lo largo del tiempo. En el espectrograma se visualizan zonas de mayor intensidad energética, especialmente en las frecuencias bajas y medias, lo cual es esperable en señales de voz humana. Esta herramienta resulta fundamental en Procesamiento del Habla porque permite estudiar no solo la duración de los sonidos, sino también su composición frecuencial.




Figura 6. Espectrograma del audio de referencia "neko".

Luego se procedió a la extracción de características acústicas. Para cada audio se calcularon distintas variables relevantes: duración, media y desviación estándar de los MFCC, energía RMS, Zero Crossing Rate y centroide espectral. Los **MFCC** permiten representar características vinculadas a la percepción humana del sonido y son ampliamente utilizados en tareas de reconocimiento y análisis de voz. La energía **RMS** permite estimar la intensidad de la señal. El **Zero Crossing Rate** mide la frecuencia con la que la onda cruza el eje cero, lo cual puede aportar información sobre la naturaleza del sonido. Por último, el **Spectral Centroid** permite conocer la zona del espectro donde se concentra la energía.

```
{'duracion': 0.84,  
'mfcc_mean': -27.946053,  
'mfcc_std': 120.7051,  
'rms_mean': 0.068546854,  
'zcr_mean': 0.07362196180555555,  
'centroid_mean': 1361.9610816436223}
```

Figura 7. Implementación de la extracción de características acústicas.

Además de calcular estas características, se visualizó la matriz de MFCC para el audio de referencia *neko*. En el gráfico se observa la evolución temporal de los coeficientes MFCC, lo que permite analizar cómo cambian las características acústicas durante la pronunciación. Esta representación complementa el análisis de forma de onda y espectrograma, ya que resume información perceptual relevante para comparar señales de voz.




Figura 8. Representación de los coeficientes MFCC del audio de referencia "neko".

Con las características extraídas se construyó un dataset estructurado en un DataFrame. Cada registro incluye información del archivo, identificador de la frase, tipo de audio y valores acústicos calculados.

	duracion	mfcc_mean	mfcc_std	rms_mean	zcr_mean	centroid_mean	archivo	id frase	tipo
0	0.840	-27.946053	120.705101	0.068547	0.073622	1361.961082	neko_ref.mp3	neko	referencia
1	0.984	-24.623425	103.484726	0.102327	0.072297	1341.742121	raamen_ref.mp3	raamen	referencia
2	0.888	-29.422457	120.016258	0.031973	0.313424	3447.127201	sushi_ref.mp3	sushi	referencia
3	0.840	-27.211376	114.529640	0.064268	0.084328	1665.642465	mizu_ref.mp3	mizu	referencia
4	0.960	-26.005402	105.779327	0.070180	0.166882	2094.689449	densha_ref.mp3	densha	referencia
5	1.152	-23.843887	104.469002	0.082091	0.071157	1387.743054	arigatou_ref.mp3	arigatou	referencia
6	1.272	-23.376120	97.180542	0.109117	0.108521	1646.860815	konnichiwa_ref.mp3	konnichiwa	referencia
7	1.056	-25.065750	102.331200	0.102480	0.089758	1406.594118	ohayou_ref.mp3	ohayou	referencia
8	1.296	-24.389059	91.832649	0.112543	0.124786	1832.904718	sayounara_ref.mp3	sayounara	referencia
9	1.224	-25.706503	99.277008	0.085649	0.158454	2024.454333	sumimasen_ref.mp3	sumimasen	referencia
10	1.728	-24.767778	92.927284	0.113150	0.136665	1775.019532	ohayou_gozaimasu_ref.mp3	ohayou_gozaimasu	referencia
11	1.872	-22.569569	90.762321	0.098458	0.117088	1739.246406	arigatou_gozaimasu_ref.mp3	arigatou_gozaimasu	referencia
12	2.640	-22.211960	92.041000	0.081084	0.135907	1928.460049	sumimasen_eki_wa_doko_desu_ka_ref.mp3	sumimasen_eki_wa_doko_desu_ka	referencia
13	1.656	-23.082920	90.047096	0.100131	0.178964	2092.195291	watashi_wa_emi_desu_ref.mp3	watashi_wa_emi_desu	referencia
14	1.776	-23.392887	95.520386	0.090992	0.172808	2133.709672	raamen_ga_suki_desu_ref.mp3	raamen_ga_suki_desu	referencia
15	1.344	-38.261822	142.983063	0.018987	0.086460	1639.831597	arigatou_01.mp4	arigatou	usuario
16	1.472	-38.772911	144.924225	0.015817	0.076764	1801.094743	arigatou_02.mp4	arigatou	usuario
17	1.472	-39.006207	143.729935	0.017033	0.095568	1795.706980	arigatou_03.mp4	arigatou	usuario
18	1.728	-35.186829	120.071991	0.021868	0.194629	2361.794348	arigatou_gozaimasu_01.mp4	arigatou_gozaimasu	usuario
19	1.728	-39.501678	124.569214	0.021671	0.242267	2747.611232	arigatou_gozaimasu_02.mp4	arigatou_gozaimasu	usuario
20	1.600	-36.327885	122.944550	0.019650	0.198692	2476.891293	arigatou_gozaimasu_03.mp4	arigatou_gozaimasu	usuario

Figura 9. Construcción del dataset de características acústicas.

El dataset integró 15 audios de referencia y 42 audios de usuario. Esto permitió realizar un análisis exploratorio comparando ambos grupos. Una de las primeras observaciones fue que los audios de referencia tuvieron una duración promedio aproximada de 1,35 segundos, mientras que los audios del usuario presentaron una duración promedio aproximada de 1,72 segundos. Esta diferencia indica que las pronunciaciones humanas grabadas por el usuario tienden a ser más extensas que las generadas por síntesis de voz, posiblemente debido a pausas, ritmo personal o menor fluidez al pronunciar en un idioma extranjero.

tipo		tipo	
usuario	42	referencia	1.345600
referencia	15	usuario	1.723429

Figura 10. Dataset consolidado con características acústicas extraídas.




Figura 11. Comparación de duración promedio entre audios de referencia y audios del usuario.

Para ampliar el conjunto de datos, se aplicaron técnicas de **Data Augmentation** sobre los audios del usuario. El notebook generó versiones sintéticas modificando la velocidad, el tono y agregando ruido leve. En particular, se crearon audios más rápidos, más lentos, con tono más alto, con tono más bajo y con ruido controlado. Como resultado se obtuvieron 210 audios sintéticos. Esta etapa permite enriquecer

el dataset y observar cómo pequeñas modificaciones en la señal afectan las características acústicas. Además, resulta útil para simular variaciones que podrían aparecer en escenarios reales, como diferencias de velocidad al hablar, tono de voz o presencia de ruido ambiente.

```
Cantidad de audios sintéticos generados: 210

['arigatou_01_fast.wav',
 'arigatou_01_noise.wav',
 'arigatou_01_pitch_down.wav',
 'arigatou_01_pitch_up.wav',
 'arigatou_01_slow.wav',
 'arigatou_02_fast.wav',
 'arigatou_02_noise.wav',
 'arigatou_02_pitch_down.wav',
 'arigatou_02_pitch_up.wav',
 'arigatou_02_slow.wav']
```

Figura 12. Implementación de técnicas de Data Augmentation sobre audios del usuario.

La comparación de pronunciación se realizó a partir de los MFCC. Para cada audio se obtuvo un vector promedio de coeficientes MFCC y luego se calculó la distancia euclidiana entre el vector del audio de referencia y el vector del audio del usuario. A menor distancia, mayor similitud acústica. Posteriormente, esa distancia fue transformada en un puntaje de similitud entre 0 y 100. El sistema también definió una clasificación automática en cuatro niveles: “Excelente”, “Buena”, “Regular” y “Necesita mejorar”.

```
def vector_mfcc_promedio(ruta_audio, sr=16000):
    """
    Obtiene el vector promedio de MFCC de un audio.
    """
    y, sr = cargar_audio(ruta_audio, sr=sr)
    mfcc = librosa.feature.mfcc(y=y, sr=sr, n_mfcc=13)
    return np.mean(mfcc, axis=1)

def calcular_similitud(ruta_referencia, ruta_usuario):
    """
    Calcula similitud entre dos audios usando distancia euclidiana
    entre vectores promedio de MFCC.
    """
    vec_ref = vector_mfcc_promedio(ruta_referencia)
    vec_user = vector_mfcc_promedio(ruta_usuario)

    distancia = euclidean(vec_ref, vec_user)

    # Conversión simple de distancia a score entre 0 y 100
    score = 100 / (1 + distancia / 100)

    return round(score, 2), round(distancia, 2)
```

```
def clasificar_pronunciacion(score):
    """
    Clasifica la pronunciación según el score de similitud.
    """
    if score >= 85:
        return "Excelente"
    elif score >= 70:
        return "Buena"
    elif score >= 55:
        return "Regular"
    else:
        return "Necesita mejorar"
```

Figura 13. Algoritmo de cálculo de similitud y clasificación de pronunciación.

En la ejecución realizada, los puntajes obtenidos se ubicaron en valores bajos, por lo que la mayoría de las muestras fueron clasificadas como “Necesita mejorar”. Esto no implica necesariamente que todas las pronunciaciones sean incorrectas desde el punto de vista lingüístico, sino que existe una distancia acústica considerable respecto de la referencia generada por gTTS. Este resultado también evidencia una limitación importante del enfoque: comparar únicamente mediante distancia entre MFCC promedio puede ser sensible a diferencias de ritmo, duración, tono, volumen y estilo de pronunciación.

	archivo_usuario	id_frase	texto_japones	score_similitud	distancia_mfcc	clasificacion
0	arigatou_01.mp4	arigatou	ありがとう	34.66	188.54	Necesita mejorar
1	arigatou_02.mp4	arigatou	ありがとう	33.76	196.17	Necesita mejorar
2	arigatou_03.mp4	arigatou	ありがとう	33.87	195.21	Necesita mejorar
3	arigatou_gozaimasu_01.mp4	arigatou_gozaimasu	ありがとうございます	41.86	138.92	Necesita mejorar
4	arigatou_gozaimasu_02.mp4	arigatou_gozaimasu	ありがとうございます	38.01	163.08	Necesita mejorar
5	arigatou_gozaimasu_03.mp4	arigatou_gozaimasu	ありがとうございます	40.09	149.46	Necesita mejorar
6	densha_01.mp4	densha	でんしゃ	29.87	234.76	Necesita mejorar
7	densha_02.mp4	densha	でんしゃ	38.86	157.36	Necesita mejorar
8	densha_03.mp4	densha	でんしゃ	28.40	252.11	Necesita mejorar
9	konnichiwa_01.mp4	konnichiwa	こんにちは	32.31	209.49	Necesita mejorar
10	konnichiwa_02.mp4	konnichiwa	こんにちは	34.36	191.06	Necesita mejorar
11	konnichiwa_03.mp4	konnichiwa	こんにちは	48.00	108.33	Necesita mejorar
12	mizu_01.mp4	mizu	みず	38.21	161.69	Necesita mejorar
13	mizu_02.mp4	mizu	みず	37.75	164.92	Necesita mejorar
14	mizu_03.mp4	mizu	みず	35.48	181.84	Necesita mejorar
15	neko_01.mp4	neko	ねこ	40.11	149.30	Necesita mejorar
16	neko_02.mp4	neko	ねこ	34.36	191.00	Necesita mejorar
17	neko_03.mp4	neko	ねこ	37.03	170.07	Necesita mejorar
18	ohayou_01.mp4	ohayou	おはよう	35.80	179.32	Necesita mejorar
19	ohayou_02.mp4	ohayou	おはよう	35.80	179.32	Necesita mejorar
20	ohayou_03.mp4	ohayou	おはよう	31.15	221.03	Necesita mejorar

Figura 14. Resultados obtenidos para las grabaciones del usuario.

En los resultados generales se obtuvo un promedio de similitud cercano a 36,88. Al ordenar los audios por puntaje, se observó que algunas frases o palabras alcanzaron

valores más altos que otras. Entre los resultados con mayor similitud aparecieron expresiones como *konnichiwa*, *sushi*, *watashi wa Emi desu*, *raamen ga suki desu*, *ohayou gozaimasu* y *arigatou gozaimasu*.

	archivo_usuario	id_frase	texto_japones	score_similitud	distancia_mfcc	clasificacion
11	konnichiwa_03.mp4	konnichiwa	こんにちは	48.00	108.33	Necesita mejorar
37	sushi_03.mp4	sushi	すし	45.25	121.00	Necesita mejorar
40	watashi_wa_emi_desu_03.mp4	watashi_wa_emi_desu	わたしはエミです	44.70	123.72	Necesita mejorar
38	watashi_wa_emi_desu_01.mp4	watashi_wa_emi_desu	わたしはエミです	44.12	126.68	Necesita mejorar
27	raamen_ga_suki_desu_02.mp4	raamen_ga_suki_desu	ラーメンが好きです	43.49	129.92	Necesita mejorar
36	sushi_02.mp4	sushi	すし	42.98	132.68	Necesita mejorar
22	ohayou_gozaimasu_02.mp4	ohayou_gozaimasu	おはようございます	42.06	137.78	Necesita mejorar
3	arigatou_gozaimasu_01.mp4	arigatou_gozaimasu	ありがとうございます	41.86	138.92	Necesita mejorar
39	watashi_wa_emi_desu_02.mp4	watashi_wa_emi_desu	わたしはエミです	40.87	144.71	Necesita mejorar
34	sumimasen_eki_wa_doko_desu_ka_01.mp4	sumimasen_eki_wa_doko_desu_ka	すみません 駅はどこですか	40.75	145.42	Necesita mejorar
32	sumimasen_02.mp4	sumimasen	すみません	40.74	145.49	Necesita mejorar
15	neko_01.mp4	neko	ねこ	40.11	149.30	Necesita mejorar
5	arigatou_gozaimasu_03.mp4	arigatou_gozaimasu	ありがとうございます	40.09	149.46	Necesita mejorar
21	ohayou_gozaimasu_01.mp4	ohayou_gozaimasu	おはようございます	39.32	154.31	Necesita mejorar

Figura 15. Ranking de pronunciaciones según puntaje de similitud.

También se generó un gráfico de promedio de similitud por palabra o frase, donde se observan diferencias entre los distintos elementos del vocabulario. Este gráfico permite identificar cuáles pronunciaciones se acercaron más a la referencia y cuáles presentaron mayor distancia acústica. Por ejemplo, algunas frases completas obtuvieron promedios superiores a ciertas palabras aisladas, lo que demuestra que la dificultad no depende únicamente de la longitud del enunciado, sino también de la familiaridad, el ritmo y la forma en que fue pronunciado.




Figura 16. Promedio de similitud obtenido para cada palabra o frase analizada

Finalmente, el notebook permitió comparar visualmente un audio de referencia con una grabación del usuario. Se seleccionó el caso de *arigatou*, mostrando primero los reproductores de audio correspondientes y luego las formas de onda de ambos archivos.




Figura 17. Comparación de audios de referencia y usuario para la palabra "arigatou".

En la comparación visual se observan diferencias claras en la amplitud, duración y distribución temporal de la señal. La referencia presenta una forma de onda más

compacta y regular, mientras que la grabación del usuario muestra una duración mayor y variaciones distintas en la intensidad.




Figura 18. Comparación de formas de onda entre referencia y usuario.

También se compararon los MFCC de ambos audios, permitiendo observar diferencias en la representación acústica de la pronunciación. Esta comparación visual complementa el análisis numérico y ayuda a comprender por qué el sistema asigna determinado puntaje de similitud.




Figura 19. Comparación de representaciones MFCC entre referencia y usuario para la palabra "arigatou".

Conclusiones

Los resultados obtenidos permitieron observar diferencias claras entre las pronunciaciones generadas automáticamente y las grabaciones realizadas por el usuario. Una de las primeras observaciones fue que las pronunciaciones humanas

presentaron, en promedio, una duración mayor que las referencias generadas mediante síntesis de voz, evidenciando la influencia que tienen el ritmo, las pausas y la fluidez al momento de hablar un idioma extranjero.

Asimismo, el análisis de las características acústicas mostró que palabras y frases aparentemente sencillas pueden presentar niveles de similitud muy diferentes respecto de la referencia. Esto permitió comprobar que la pronunciación no depende únicamente de reproducir correctamente una palabra, sino también de factores como la entonación, la velocidad y la estructura temporal de la señal de voz.

La utilización de MFCC como representación acústica permitió obtener una medida objetiva para comparar pronunciaciones y detectar diferencias entre las muestras analizadas. Sin embargo, los resultados también mostraron que una comparación basada únicamente en características promedio puede verse afectada por variaciones naturales presentes en la voz humana, lo que explica que algunas pronunciaciones perceptualmente correctas no siempre obtengan los puntajes más altos de similitud.

Como mejora futura, sería interesante incorporar grabaciones realizadas por hablantes nativos japoneses como referencia, ampliar la cantidad de participantes y evaluar técnicas de comparación más avanzadas que contemplen mejor las diferencias temporales entre pronunciaciones. Esto permitiría obtener evaluaciones más precisas y acercar el sistema a escenarios reales de aprendizaje de idiomas.

En conjunto, Pronuncia permitió demostrar que es posible aplicar técnicas de Procesamiento del Habla para analizar pronunciaciones de forma automatizada, obteniendo resultados cuantificables que sirven como punto de partida para la construcción de herramientas de apoyo al aprendizaje y práctica de idiomas.

11. BIBLIOGRAFÍA:

Librosa Development Team. (2025). *Librosa Documentation*. <https://librosa.org>

McKinney, W. (2022). *Python for Data Analysis* (3rd ed.). O'Reilly Media.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.

Raschka, S., Liu, Y., & Mirjalili, V. (2022). *Machine Learning with Python and Scikit-Learn*. Packt Publishing.

Stevens, S., Volkman, J., & Newman, E. (1937). A scale for the measurement of the psychological magnitude pitch. *Journal of the Acoustical Society of America*, 8(3), 185–190.