

# **PronunciA: Evaluación automática de pronunciación en japonés mediante procesamiento del habla e inteligencia artificial**

**Instituto Superior Politécnico Córdoba**

**Tecnicatura Superior en Ciencia de Datos e Inteligencia Artificial**

**Técnicas de Procesamiento del Habla**



**Alumnos:**

- Emilce Robles
- Ian Marini

**Docente:** Rubén Emmanuel Giudice Bojanich

9 de junio de 2026

## **PronunciA: Evaluación automática de pronunciación en japonés**

### **Resumen**

El presente informe técnico describe el desarrollo de PronunciA, un prototipo educativo orientado a la evaluación automática de pronunciación en japonés mediante procesamiento del habla e inteligencia artificial. El sistema compara grabaciones de usuarios con audios de referencia generados mediante síntesis de voz, extrae características acústicas y asigna un puntaje de similitud. La implementación se realizó en Python y Jupyter Notebook, utilizando bibliotecas para carga, análisis, visualización y tratamiento de audio. El conjunto de trabajo incluyó 15 audios de referencia, 42 audios de usuario y 210 audios sintéticos generados por aumento de datos. Los resultados mostraron diferencias relevantes entre las referencias y las grabaciones humanas, especialmente en duración, ritmo e intensidad. La similitud promedio obtenida fue cercana a 36,88 puntos, con predominio de clasificaciones en el nivel “Necesita mejorar”. El enfoque permitió validar un flujo funcional, aunque presenta limitaciones al depender de MFCC promedio y de referencias sintéticas.

*Palabras clave:* procesamiento del habla, pronunciación, japonés, MFCC, inteligencia artificial, audio.

### **Introducción**

El aprendizaje de idiomas requiere retroalimentación constante sobre la pronunciación. En idiomas con estructuras fonéticas diferentes al español, como el japonés, los estudiantes pueden tener dificultades para identificar errores de ritmo, entonación o articulación sin la asistencia de docentes o hablantes nativos. Ante esta necesidad, PronunciA propone una herramienta de apoyo capaz de analizar grabaciones de voz y compararlas con pronunciaciones de referencia.

El objetivo general del proyecto fue desarrollar un sistema de evaluación automática de pronunciación que permitiera comparar audios de usuarios con audios de referencia en japonés. La solución integra adquisición de audio, preprocesamiento, extracción de características acústicas, análisis exploratorio, aumento de datos y cálculo de similitud. El producto se concibió como un prototipo académico y no como un evaluador lingüístico definitivo.

### **Metodología**

El desarrollo se organizó en un único notebook de Jupyter. Primero se definió un vocabulario base de 15 elementos en japonés, distribuido entre palabras simples, expresiones cotidianas y frases breves. A partir de ese vocabulario se generaron audios de referencia

mediante Google Text-to-Speech configurado en japonés. Los archivos se almacenaron en la carpeta audios/referencia y el notebook fue diseñado para regenerarlos automáticamente cuando no estuvieran disponibles.

Luego se incorporaron 42 grabaciones de usuario en formato .mp4, ubicadas en audios/usuario. Para garantizar compatibilidad con el flujo de procesamiento, se adaptó la carga y conversión de archivos cuando fue necesario. Las señales fueron normalizadas a una frecuencia de muestreo uniforme; en la prueba documentada para la palabra neko se utilizó una frecuencia de 16.000 Hz y una duración aproximada de 0,84 segundos.

La extracción de características incluyó duración, coeficientes cepstrales en las frecuencias de Mel (MFCC), energía RMS, tasa de cruces por cero y centroide espectral. Estas variables permitieron representar propiedades temporales, energéticas y frecuenciales de cada señal. El análisis y la manipulación de datos se apoyaron en estructuras tabulares y operaciones reproducibles en Python (Librosa Development Team, 2025; McKinney, 2022).

Para ampliar el conjunto de entrenamiento y simular variaciones reales, se aplicó aumento de datos sobre las grabaciones del usuario. Se generaron versiones con cambios de velocidad, tono y ruido leve, obteniendo 210 audios sintéticos. La comparación de pronunciación se realizó calculando la distancia euclidiana entre vectores promedio de MFCC de referencia y usuario. Luego, la distancia se transformó en un puntaje de similitud entre 0 y 100 y en una clasificación cualitativa: “Excelente”, “Buena”, “Regular” o “Necesita mejorar”.

## Resultados

El dataset consolidado integró 15 audios de referencia y 42 audios de usuario. El análisis descriptivo mostró que los audios de referencia tuvieron una duración promedio aproximada de 1,35 segundos, mientras que los audios de usuario alcanzaron una duración promedio aproximada de 1,72 segundos. Esta diferencia sugiere que las grabaciones humanas incluyeron pausas, variaciones de ritmo o menor fluidez respecto de las referencias sintéticas.

La evaluación por similitud produjo un promedio general cercano a 36,88 puntos. La mayoría de las muestras se ubicó en la categoría “Necesita mejorar”. Este resultado no debe interpretarse automáticamente como error lingüístico absoluto, ya que el método compara distancia acústica frente a una voz sintética y puede penalizar diferencias naturales de duración, volumen, tono o estilo de habla.

Las pronunciaciones con mejores puntajes relativos incluyeron expresiones como konnichiwa, sushi, watashi wa Emi desu, raamen ga suki desu, ohayou gozaimasu y arigatou gozaimasu. También se observaron diferencias visuales entre referencia y usuario en formas

de onda y matrices MFCC, especialmente para el caso arigatou, donde la grabación humana presentó mayor duración y una distribución temporal distinta.

### Matriz de confusión

Para construir una matriz de confusión real se requieren etiquetas de verdad terreno, por ejemplo una validación manual realizada por un docente o hablante nativo que indique si cada pronunciación es correcta o incorrecta. La documentación disponible no incluye esas etiquetas externas ya que el modelo arrojó como resultado “Necesita mejorar” por lo que excelente, buena o regular no cuenta con información. En su lugar, se presenta la matriz estructural que debería completarse cuando se incorpore evaluación humana con más resultados en cuanto a clasificación.

**Tabla 1**

*Matriz de confusión binaria pendiente de etiquetado humano*

| Predicción / Real                             | Correcta  | Incorrecta |
|-----------------------------------------------|-----------|------------|
| <b>Aceptable</b><br>(Excelente/Buena/Regular) | VP<br>N/D | FP<br>N/D  |
| <b>No aceptable</b><br>(Necesita mejorar)     | FN<br>N/D | VN<br>N/D  |

*Nota.* N/D significa no disponible. La matriz queda definida para una etapa posterior de validación supervisada con etiquetas humanas.

### Discusión y limitaciones

El sistema demostró que es posible construir un flujo reproducible para comparar pronunciaciones mediante características acústicas. Sin embargo, el uso de MFCC promedio reduce la información temporal de la señal. Esto puede afectar la evaluación de frases con distinta velocidad o pausas, porque dos pronunciaciones perceptualmente similares pueden presentar distancias elevadas si no están alineadas temporalmente. Una mejora técnica sería incorporar alineamiento temporal dinámico, referencias grabadas por hablantes nativos, más participantes y validación supervisada con métricas como exactitud, precisión, sensibilidad y F1 (Pedregosa et al., 2011; Raschka et al., 2022).

## Reflexión ética

El proyecto trabaja con grabaciones de voz, un tipo de dato personal sensible porque puede identificar a una persona o revelar rasgos de edad, acento, origen lingüístico y condiciones del habla. Por ello, cualquier uso fuera del contexto académico debería incluir consentimiento informado, finalidad explícita, almacenamiento seguro, minimización de datos y posibilidad de eliminación de las grabaciones.

También debe evitarse presentar el puntaje de similitud como diagnóstico absoluto de calidad lingüística. El modelo compara señales acústicas frente a una referencia sintética y puede castigar acentos, variaciones individuales o condiciones de grabación. En consecuencia, Pronuncia debe entenderse como una herramienta de apoyo y práctica, no como mecanismo excluyente de evaluación educativa.

## Enlace al código

El código fuente y la documentación del proyecto se encuentran disponibles en el repositorio de GitHub: <https://github.com/emilce-robles/ISPC-Procesamiento-del-Habla-Pronuncia>

## Conclusiones

Pronuncia permitió aplicar técnicas de procesamiento del habla para evaluar pronunciaciones en japonés mediante comparación acústica. El prototipo generó audios de referencia, procesó grabaciones reales, extrajo características, amplió datos mediante augmentation y produjo puntajes interpretables. Los resultados evidenciaron diferencias claras entre voz sintética y voz de usuario, así como la necesidad de incorporar validación humana para calcular una matriz de confusión real y fortalecer la confiabilidad del sistema.

## Referencias

Librosa Development Team. (2025). Librosa documentation. <https://librosa.org>

McKinney, W. (2022). Python for data analysis (3rd ed.). O'Reilly Media.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

Raschka, S., Liu, Y., & Mirjalili, V. (2022). *Machine learning with Python and scikit-learn*. Packt Publishing.

Robles, E., & Marini, I. (2026). ISPC-Procesamiento-del-Habla-PronunciA [Repositorio de código]. GitHub. <https://github.com/emilce-robles/ISPC-Procesamiento-del-Habla-PronunciA>

Stevens, S., Volkman, J., & Newman, E. (1937). A scale for the measurement of the psychological magnitude pitch. *Journal of the Acoustical Society of America*, 8(3), 185–190.